



SISTEMA DE REHABILITACIÓN BASADO EN ANÁLISIS BIOMECÁNICO Y VISIÓN ESTÉREO

PROFESORES:

M en C Eduardo de Ávila Armenta

Dr Alberto Luque Chang

INTEGRANTES:

José de Jesús Fernández García

Jorge Enrique González Sevilla

4 de abril de 2025

Índice general

1. Introducción.....	5
2. Justificación.....	6
2.1. Objetivos.....	7
2.2. Antecedentes.....	7
3. Metodología	9
3.1. Regresión	9
3.1.1. Trayectorias a analizar	9
3.1.2. Adquisición de los datos	10
3.1.3. Limpieza de datos	10
3.1.4. Función objetivo a minimizar	11
3.1.5. Trayectorias ajustadas	12
3.2. Clasificación	15
3.2.1. Tipos de posturas a clasificar.....	15
3.2.2. Obtención de los ángulos de Euler para la clasificación.....	15
3.2.3. Limpieza de datos	18
3.2.4. Creación del conjunto de datos.....	21
3.2.5. Visualización de los datos	22
3.2.6. División del conjunto de datos (entrenamiento y prueba)	24
3.2.7. Selección de los mejores hiperparametros para el modelo de clasificación	25
4. Resultados.....	27
4.1. Clasificación	27
4.1.1. F1 Score de cada combinación de hiperparametros	27
4.1.2. Resultados en el conjunto de prueba	31
4.2. Regresión	32
4.3. Sistema informático	34
5. Discusión y conclusiones	38
5.1. Regresión	38
5.2. Clasificación	38

5.3. Conclusión general	39
Referencias	40
Anexos.....	41
1. Combinaciones de hiperparametros	41
2. Interpretación de las métricas de evaluación para clasificación	42

Índice de figuras

Figura 1. Funcionamiento de una cámara Pinhole.	6
Figura 2. Ejemplo de sistemas de coordenadas asociados a puntos característicos del cuerpo humano.	16
Figura 3. Gráfico boxplot.	19
Figura 4. Ejemplo de hiperesfera en R^3 que se extiende desde el centroide de la clase positiva hasta cubrir un cierto porcentaje de datos de la clase positiva.....	20
Figura 5. Flujo de entrenamiento para la selección del mejor modelo.....	26
Figura 6. Menu del sistema informatico.	35
Figura 7. Visualización de los datos y creación de rutinas en el sistema informático.....	36
Figura 8. Clasificación de posturas en el sistema informático.....	36
Figura 9. Diccionario de hiperparametros.....	41
Figura 10. Matriz de confusión.	42
Figura 11. Métrica F1 Score.	43

Índice de tablas

Tabla 1. Trayectorias corporales a analizar.	10
Tabla 2. Resultados de la limpieza de datos para cada trayectoria.	11
Tabla 3. Trayectorias ajustadas.	13
Tabla 4. Trayectorias ajustadas en puntos específicos.	14
Tabla 5. Posturas a clasificar.....	15
Tabla 6. Matriz de rotación.	17
Tabla 7. Metodología utilizada para el cálculo de los ángulos de Euler.....	17

Tabla 8. Numero de ejemplos por postura.	18
Tabla 9. Resultados de la limpieza de datos para la clasificación.	21
Tabla 10. Conjuntos de datos para cada postura.....	21
Tabla 11. Desbalance de clases para el problema de clasificación.....	22
Tabla 12. Separabilidad de las clases por característica.	23
Tabla 13. Conjuntos de datos para entrenamiento y prueba.	24
Tabla 14. Arquitecturas de red propuestas.....	25
Tabla 15. Resultados obtenidos en la búsqueda del mejor modelo de clasificación.	29
Tabla 16. Historial de perdida durante el entrenamiento.	30
Tabla 17. Matrices de confusión para el conjunto de prueba.	32
Tabla 18. Historial de perdida para algunas trayectorias.	34
Tabla 19. Combinaciones de todos los hiperprametros.	42

1. Introducción

La integración de tecnologías emergentes como la inteligencia artificial (IA) en la rehabilitación física está transformando significativamente el paradigma tradicional, ofreciendo soluciones innovadoras y efectivas en la evaluación y tratamiento de diversas patologías musculoesqueléticas. El presente proyecto tiene como objetivo aplicar técnicas de machine learning en el ámbito de la rehabilitación física para evaluar con precisión los movimientos corporales y proporcionar retroalimentación objetiva a los pacientes y especialistas en salud.

La rehabilitación física se enfrenta a diversos desafíos, especialmente relacionados con la evaluación precisa y objetiva del desempeño del paciente durante las sesiones terapéuticas. Los métodos convencionales suelen depender del juicio subjetivo del terapeuta, lo cual puede dificultar un seguimiento adecuado del progreso y limitar la efectividad de los tratamientos implementados. Frente a esta problemática, se propone desarrollar un sistema basado en visión estéreo utilizando dos cámaras USB económicas que permitirán una captura detallada y una evaluación precisa de los movimientos corporales en tres dimensiones, utilizando técnicas avanzadas de machine learning.

2. Justificación

La principal razón por la cual se pretende desarrollar un sistema de visión estéreo en la terapia física es para que sea una herramienta que favorezca y ayude a los fisioterapeutas durante el proceso de rehabilitación de los pacientes.

El fundamento del sistema radica en la técnica de visión estéreo, que imita la percepción humana mediante triangulación desde múltiples puntos de vista, permitiendo una percepción precisa de la profundidad espacial. Este sistema se complementa con modelos avanzados de deep learning que facilitan la identificación automática de puntos anatómicos clave para la evaluación biomecánica precisa. La Figura 1 muestra un concepto importante en la visión estéreo, el modelo de cámara Pinhole, el cual es un modelo matemático que describe la relación matemática de un punto 3D y su proyección en el plano de imagen 2D de la cámara.




Figura 1. Funcionamiento de una cámara Pinhole.

Además, dada la idea de que un sistema informático por lo general no se adquiere debido a su alto costo, el sistema que se pretende desarrollar es económico y fácil de usar, ya que solo necesita de una computadora con sistema operativo Linux donde pueda correr el sistema y de dos cámaras USB de bajo costo.

2.1. Objetivos

Como objetivo general se busca innovar con un sistema informático de bajo costo que implementa visión estéreo mediante dos cámaras USB, de tal forma que sirva como herramienta en el área de la terapia física para tareas de análisis del movimiento y clasificación de posturas de ejercicios para la rehabilitación física.

Objetivos específicos:

- Crear un sistema informático económico que implemente visión estéreo, que sea capaz de usarse en una clínica de terapia física y que sea fácil de instalar.
- Implementar estimaciones 3D de partes características del cuerpo humano en tiempo real.
- Capturar el movimiento corporal en tiempo real
- Clasificar posturas corporales durante sesiones de rehabilitación física
- Mostrar la correcta ejecución de ejercicios durante sesiones de rehabilitación física
- Conseguir que el sistema informático sea una herramienta que favorezca y ayude a los fisioterapeutas, ofreciendo soluciones y alternativas a tareas ya existentes para que se lleven de una mejor manera y posiblemente más efectiva.

2.2. Antecedentes

En la terapia física, los fisioterapeutas realizan muchas pruebas de evaluación a sus pacientes para determinar con exactitud los posibles tratamientos que mejor se acomodan al paciente, los cuales incluyen ejercicios para la rehabilitación física del paciente.

La implementación de la visión estéreo en sistemas informáticos para la captura de movimiento no es tan común en áreas como la salud, y muchos de los motivos se deben a que se desconocen las aplicaciones que le pueden dar a la captura de movimiento y además no es tan fácil desarrollar un sistema de visión estéreo desde cero, esto por su complejidad.

Diversas investigaciones han validado el potencial de estas tecnologías de captura de movimiento para aplicaciones clínicas en rehabilitación física. Por ejemplo, [1] demostraron cómo el sensor Kinect combinado con videojuegos interactivos puede mejorar la experiencia del paciente, ofreciendo simultáneamente una evaluación objetiva de los movimientos mediante análisis biomecánico automatizado. Por su parte, [2] desarrollaron

OpenCap, un sistema abierto que permite capturar movimientos corporales mediante smartphones, validando su precisión y accesibilidad en contextos clínicos y domiciliarios.

Adicionalmente, investigaciones recientes han aplicado técnicas de machine learning para mejorar aún más la precisión y personalización de los tratamientos. En [3] utilizaron aprendizaje no supervisado para identificar patrones de movimiento distintivos en pacientes con dolor lumbar crónico, logrando diferenciar estos patrones de individuos sanos. De manera similar, en [4] aplicaron modelos de regresión basados en aprendizaje automático para predecir cambios en patrones de movimiento durante la rehabilitación, demostrando la utilidad clínica de estas técnicas para optimizar estrategias terapéuticas.

En [5] propusieron un marco basado en redes neuronales profundas que permite evaluar automáticamente la calidad de ejercicios de rehabilitación física, proporcionando una evaluación objetiva y consistente del rendimiento del paciente. Por su parte, en [6] examinaron diferentes sistemas de seguimiento del movimiento, incluyendo visión por computadora y sensores inerciales, para determinar su precisión en aplicaciones clínicas, concluyendo que estas tecnologías pueden integrarse eficazmente en la monitorización y evaluación de ejercicios terapéuticos.

Finalmente, el trabajo [7] mostró la viabilidad y precisión de sistemas basados en visión estéreo de bajo costo para el seguimiento del movimiento corporal tridimensional, lo que confirma la idoneidad de esta tecnología para aplicaciones clínicas accesibles y efectivas.

3. Metodología

En este capítulo se detallará la metodología utilizada para cada problema, tanto para la regresión como para la clasificación. Se hablará de la adquisición de los datos, la limpieza de los datos, y del proceso de optimización.

3.1. Regresión

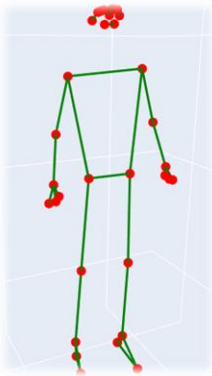
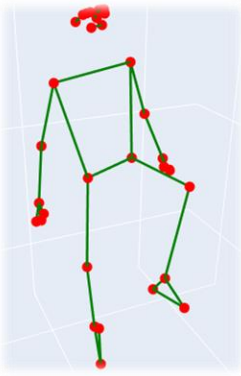
Debido a la naturaleza de los datos para el problema de regresión, tiene más sentido analizar visualmente la nube de puntos de cada punto 3D a lo largo del tiempo.

3.1.1. Trayectorias a analizar

Las trayectorias para analizar son las siguientes:

- Levantamiento de rodilla izquierda
- Levantamiento de rodilla derecha
- Levantamiento de brazos

La Tabla 1 muestra la postura inicial y final de cada trayectoria.

Nombre	Postura inicial de la trayectoria	Postura final de la trayectoria
<i>Levantamiento de rodilla izquierda</i>		




Tabla 1. Trayectorias corporales a analizar.

3.1.2. Adquisición de los datos

Los datos fueron adquiridos por medio del sistema informático desarrollado, los cuales fueron almacenados en local para su posterior uso.

Los datos están compuestos por posturas corporales a lo largo del tiempo, donde cada postura esta representada por puntos 3D característicos del cuerpo humano descritos en un sistema de coordenadas tridimensional.

Posteriormente, para cada punto 3D, se ajustará una trayectoria a la nube de puntos que genera el punto 3D a lo largo del tiempo.

3.1.3. Limpieza de datos

La limpieza de las posturas (para no agregar ruido) se realiza utilizando un método visual, la cual consiste en ir postura por postura analizando que no existan posturas fuera de lo normal, y si es que existen se eliminan.

La Tabla 2 muestra los resultados obtenidos después de la limpieza de datos.

	<i>Levantamiento de rodilla izquierda</i>	<i>Levantamiento de rodilla derecha</i>	<i>Levantamiento de brazos</i>
Numero de datos antes de la limpieza	41	47	60
Numero de datos después de la limpieza	26	29	60

Tabla 2. Resultados de la limpieza de datos para cada trayectoria.

El proceso de limpieza no es un proceso muy tardado, ya que una trayectoria a lo mucho puede tener 60 posturas diferentes.

Por lo pronto se utiliza un método visual y manual, pero podría ser de utilidad encontrar un método automático que ayude a eliminar posturas ruidosas a lo largo de la trayectoria.

3.1.4. Función objetivo a minimizar

Función objetivo a minimizar para el ajuste de trayectoria de cada punto 3D:

$$F = \frac{1}{2m} \sum_{i=1}^m \|u^{(i)} - p(t^{(i)})\|^2 \quad (1)$$

Donde:

- m : Numero de puntos 3D en la nube de puntos que describe una trayectoria
- $p(t^{(i)})$: Un punto sobre la trayectoria ajustada
- $u^{(i)}$: Un punto 3D de la nube de puntos

Además, la parametrización de la trayectoria esta descrita por la siguiente ecuación:

$$p(t) = \begin{bmatrix} x \\ y \\ z \end{bmatrix} = \begin{bmatrix} x_0 + w_{x1}t + w_{x2}t^2 \\ y_0 + w_{y1}t + w_{y2}t^2 \\ z_0 + w_{z1}t + w_{z2}t^2 \end{bmatrix} \quad (2)$$

$$p_0 = \begin{bmatrix} x_0 \\ y_0 \\ z_0 \end{bmatrix} \quad (3)$$

El punto p_0 (equ. 3) es el primer punto de la nube de puntos.

Los parámetros por estimar (entrenar) son los siguientes:

- $w_{x1}, w_{x2}, w_{y1}, w_{y2}, w_{z1}, w_{z2}$
- $t^{(1)}, \dots, t^{(m)}$

Para la parametrización de la trayectoria, se decidió utilizar polinomios de segundo orden para cada componente debido a la naturaleza de los movimientos que puede describir nuestro cuerpo partiendo de una postura y realizando el movimiento a otra postura, ya que estos por lo mucho puede ser trayectorias que se pueden curvar en un punto.

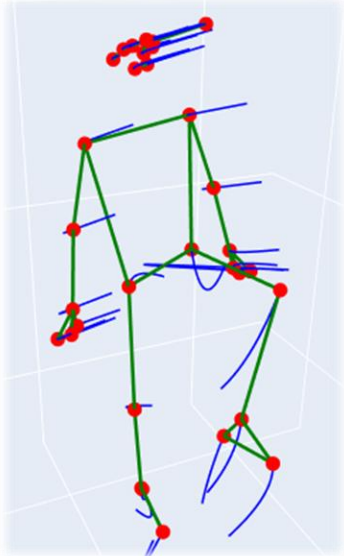
La función objetivo se minimizo utilizando el método minimize de la librería SciPy, en el cual se configuro como optimizador el algoritmo BFGS (Broyden–Fletcher–Goldfarb–Shanno algorithm).

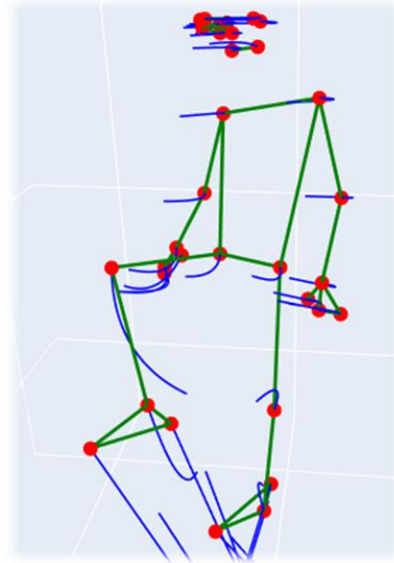

3.1.5. Trayectorias ajustadas

Una vez ajustada la trayectoria a una nube de puntos, lo que sigue es trazar la trayectoria, la cual describe un movimiento más suave para el punto 3D a lo largo del tiempo. Para esto se generan 100 puntos a lo largo de la trayectoria ajustada.

El ajuste de las trayectorias tiene como fin mostrar al paciente como se debe realizar un ejercicio en específico, mostrando una ejecución suave y precisa.

La Tabla 3 muestra cuales serían las trayectorias (en azul) que seguiría cada punto 3D después del ajuste de trayectorias.

Nombre	Trayectoria ajustada para cada punto 3D
<i>Levantamiento de rodilla izquierda</i>	

Levantamiento de rodilla derecha*Levantamiento de brazos*

NOTA: Para el ajuste de trayectorias, podría ser conveniente quedarnos solo con las trayectorias de algunos puntos, aquellos que si describen una trayectoria a lo largo del tiempo, ya que los puntos que por lo general están fijos suelen tener trayectorias ajustadas que dan malos resultados.

Tabla 3. Trayectorias ajustadas.


Para un punto 3D en particular, su trayectoria ajustada se vería como se muestra en la Tabla 4.

Nombre	Trayectoria ajustada para cada punto 3D
--------	---

left_knee

Levantamiento de rodilla izquierda


Trayectoria ajustada para la nube de puntos generada por el punto 3D “left_knee” (rodilla izquierda) a lo largo del tiempo.



right_knee

Levantamiento de rodilla derecha


Trayectoria ajustada para la nube de puntos generada por el punto 3D “right_knee” (rodilla derecha) a lo largo del tiempo.



right_elbow

Levantamiento de brazos

Trayectoria ajustada para la nube de puntos generada por el punto 3D “right_elbow” (codo derecho) a lo largo del tiempo.



Para obtener buenos resultados es indispensable que las estimaciones 3D de partes características del cuerpo sea buena, ya que malas estimaciones 3D solo agregan ruido, y si no es tratado ese ruido, los resultados pueden no ser los esperados.

Tabla 4. Trayectorias ajustadas en puntos específicos.

3.2. Clasificación

Debido a la naturaleza de los datos para el problema de clasificación, se optó por que los datos estén separados en posturas 3D y en ángulos de Euler. Cada postura 3D tiene sistemas de coordenadas asociados a cada punto 3D, de los cuales se obtienen ángulos de Euler.

3.2.1. Tipos de posturas a clasificar

Las posturas a clasificar durante las sesiones de rehabilitación física se muestran en la Tabla 5.

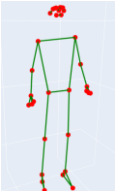
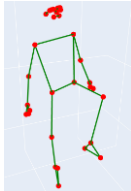
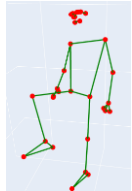
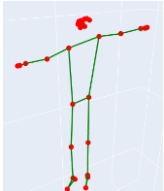
Posturas neutras		Posturas de movimiento o ejecución	
			
De pie con los brazos a los lados	De pie levantando la rodilla izquierda	De pie levantando la rodilla derecha	De pie levantando los brazos

Tabla 5. Posturas a clasificar.

Para cada postura (neutra y de movimiento) se creará un clasificador binario para determinar si el paciente está realizando la postura que se le está pidiendo o no.

Hay que recordar que todo ejercicio sigue los siguientes pasos:

1. Postura neutra
2. Postura de movimiento o ejecución
3. Postura neutra

Las rutinas para cada paciente están compuestas por una serie de ejercicios con cierto número de repeticiones cada uno, por tanto, el clasificador binario que se estará usando será de acorde al ejercicio que se está pidiendo que haga el paciente, intercambiándose tres veces para clasificar postura neutra, postura de movimiento, y finalmente, postura neutra otra vez.

3.2.2. Obtención de los ángulos de Euler para la clasificación

Para clasificar una postura se utilizarán los ángulos de Euler asociados a matrices de rotación.

Los ángulos de Euler se calculan a partir de los puntos 3D de la postura. Cada punto 3D tiene asociado un sistema de coordenadas.

La Figura 2 muestra un ejemplo de sistemas de coordenadas.




Figura 2. Ejemplo de sistemas de coordenadas asociados a puntos característicos del cuerpo humano.

Para las estimaciones de puntos 3D característicos del cuerpo es necesario contar con modelos de deep learning que detecten esos puntos 3D pero sobre una imagen, es decir, su proyección sobre la imagen. Para esta tarea se utiliza el modelo MediaPipe Pose.

MediaPipe Pose funciona en tiempo real en dispositivos móviles e infiere 33 puntos clave del cuerpo en 2D y en 3D, y además infiere una máscara de segmentación de fondo en todo el cuerpo a partir de una imagen RGB. Cabe destacar que los puntos 3D están conformados por los puntos 2D y otro valor para cada punto que indica la profundidad relativa de dicho punto clave.

El modelo MediaPipe Pose tiene las siguientes características:

- Presenta un seguimiento de la postura del cuerpo a lo largo del tiempo
- Presenta una arquitectura de red encoder-decoder para predecir mapas de calor para todas las articulaciones presentes sobre la imagen y regresión para las coordenadas de cada punto clave
- Es muy importante que la cabeza de la persona a detectar este visible en la imagen, ya que se cuenta con un detector facial rápido que detecta primero la cabeza y después de eso predice parámetros de alineación adicionales específicos de la persona, como lo son:
 - Punto medio entre las caderas de la persona
 - Tamaño del círculo que circunda a toda la persona
 - Inclinación

Los ángulos de Euler se calculan de la siguiente manera:

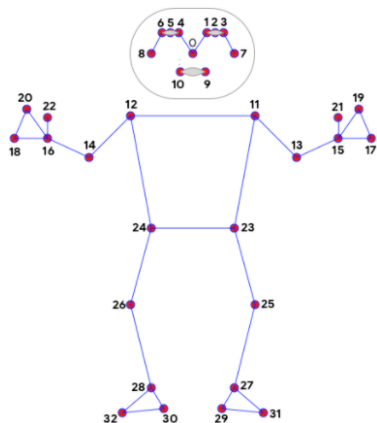
- Se eligen dos sistemas de coordenadas asociados a dos puntos 3D
- Se expresa la matriz de rotación de un sistema de coordenadas con respecto al otro
- A partir de la matriz de rotación, se calculan los ángulos de Euler asociados a la matriz de rotación

La tabla 6 muestra la relación que existe entre los ángulos de Euler y la matriz de rotación.

Matriz de rotación en R^3
$R(\Phi, \theta, \Psi) = R_z(\Phi)R_y(\theta)R_x(\Psi)$
<i>Los ángulos de Euler están expresados en radianes.</i>

Tabla 6. Matriz de rotación.

Lo que se propuso para el cálculo de los ángulos de Euler se muestra en la Tabla 7.

Puntos de interés		Puntos característicos del cuerpo humano dados por el modelo MediaPipe Pose	
Izquierda	Derecha		
25 ← 27	26 ← 28		0. nose
23 ← 25	24 ← 26		1. left_eye_inner
11 ← 23	12 ← 24		2. left_eye
11 ← 13	12 ← 14		3. left_eye_outer
13 ← 15	14 ← 16		4. right_eye_inner
23 ← 11	24 ← 12		5. right_eye
11 ← 0	12 ← 0		6. right_eye_outer
			7. left_ear
			8. right_ear
			9. mouth_left
			10. mouth_right
			11. left_shoulder
			12. right_shoulder
			13. left_elbow
			14. right_elbow
			15. left_wrist
		16. right_wrist	
		17. left_pinky	
		18. right_pinky	
		19. left_index	
		20. right_index	
		21. left_thumb	
		22. right_thumb	
		23. left_hip	
		24. right_hip	
		25. left_knee	
		26. right_knee	
		27. left_ankle	
		28. right_ankle	
		29. left_heel	
		30. right_heel	
		31. left_foot_index	
		32. right_foot_index	

$\mathbf{p} \leftarrow \mathbf{q}$

Sistema de coordenadas \mathbf{q} con respecto al sistema de coordenadas \mathbf{p} (se construye \mathbf{q} a partir de \mathbf{p}).

NOTA: Todos los puntos 3D están expresados en un sistema de coordenadas global (principal).

Tabla 7. Metodología utilizada para el cálculo de los ángulos de Euler.

Para una postura en particular se cuenta con:

$$(14)(3) = 42 \text{ características}$$

Dado que los ángulos de Euler están expresados en radianes, al construir el conjunto de datos no será necesario normalizar los datos.

La Tabla 8 muestra cuantos ejemplos se tienen para cada postura.

Postura	Numero de ejemplos (instancias)
<i>Posturas aleatorias</i>	
Forman el conjunto de datos para la clase negativa	888 posturas (instancias)
<i>Postura neutra:</i>	
De pie con los brazos a los lados	224 posturas (instancias)
<i>Postura de movimiento o ejecución:</i>	
De pie levantando la rodilla izquierda	171 posturas (instancias)
<i>Postura de movimiento o ejecución:</i>	
De pie levantando la rodilla derecha	180 posturas (instancias)
<i>Postura de movimiento o ejecución:</i>	
De pie levantando los brazos	204 posturas (instancias)

Tabla 8. Numero de ejemplos por postura.

3.2.3. Limpieza de datos

La limpieza de datos se hará de dos formas diferentes:

- Para la clase positiva, se seguirá una estrategia basada en el gráfico de boxplot
- Para la clase negativa, se seguirá una estrategia que consta en eliminar todas aquellas posturas que sean muy similares a las posturas de la clase positiva.

Para los datos de la clase positiva, es importante eliminar aquellas posturas que no pertenecen a la postura que se desea clasificar. Debido a la naturaleza de cómo se obtienen los datos, es posible que se agregue ruido a los datos.

La estrategia planteada para hacer la limpieza de los datos de la clase positiva consiste en lo siguiente:

1. Se elige una característica.
2. Se detectan aquellas posturas las cuales forman parte de los valores atípicos dado

por la gráfica del boxplot, tal como se muestra en la Figura 3.

Se consideran valores atípicos a todos aquellos valores:

- Que estén por debajo de $Q1 - 1.5 \text{ IQR}$
- Que estén por encima de $Q3 + 1.5 \text{ IQR}$

Donde:

- $Q1$: Valor debajo del cual se encuentra el 25% de los datos
- $Q3$: Valor debajo del cual se encuentra el 75% de los datos
- IQR : Rango intercuartil (medida de dispersión, ya que, si IQR es grande, implica que existe mucha dispersión de los datos)

3. Se repite el proceso con todas las características, y al final se eliminan las posturas acumuladas del paso anterior.




Figura 3. Gráfico boxplot.

Para los datos de la clase negativa, dado que son posturas aleatorias, es posible que existan datos que sean muy similares a los de la clase positiva. Estos datos se desean eliminar de la clase negativa.

La estrategia planteada para eliminar datos de la clase negativa que son muy similares a la clase positiva consiste en lo siguiente:

- Se define el centroide de la clase positiva
- Se define una hipersfera centrada en el centroide
- Se extiende la hipersfera hasta cubrir un cierto porcentaje de datos de la clase positiva

- El porcentaje de datos de la clase positiva que debe cubrir la hiperesfera es del 75 % (así se definió)
- Los datos de la clase negativa que se encuentran dentro de la hiperesfera serán los datos que no se tomarán en cuenta

La Figura 4 muestra una representación mas visual de como la hiperesfera puede contener algunos puntos 3D y otros simplemente están fuera.

El hecho de utilizar una hiperesfera es por la suposición que se hace con respecto a los datos de la clase positiva, ya que por su naturaleza se estima que la nube de puntos puede estar agrupada de forma compacta.




Figura 4. Ejemplo de hiperesfera en R^3 que se extiende desde el centroide de la clase positiva hasta cubrir un cierto porcentaje de datos de la clase positiva.

Los resultados después de la limpieza de datos se muestran en la Tabla 9.

Postura	Numero de ejemplos después de la limpieza
Postura neutra:	Clase positiva: 166
De pie con los brazos a los lados	Se eliminaron 58 ejemplos de 224 (25.89 %)
	Clase negativa: 888
	Dada la estrategia propuesta, no se eliminó ningún ejemplo
Postura de movimiento o ejecución:	Clase positiva: 76
De pie levantando la rodilla izquierda	Se eliminaron 95 ejemplos de 171 (55.55 %)
	Clase negativa: 888
	Dada la estrategia propuesta, no se eliminó ningún ejemplo
Postura de movimiento o ejecución:	Clase positiva: 99
De pie levantando la rodilla derecha	Se eliminaron 81 ejemplos de 180 (45.0 %)

	Clase negativa: 885 <i>Dada la estrategia propuesta, se eliminaron 3 ejemplos de 888 (0.33 %)</i>
Postura de movimiento o ejecución: <i>De pie levantando los brazos</i>	Clase positiva: 99 <i>Se eliminaron 105 ejemplos de 204 (51.47 %)</i>
	Clase negativa: 888 <i>Dada la estrategia propuesta, no se eliminó ningún ejemplo</i>

Tabla 9. Resultados de la limpieza de datos para la clasificación.

3.2.4. Creación del conjunto de datos

Una vez hecha la limpieza de datos tanto para la clase positiva como para la clase negativa, se procede a construir el conjunto de datos final.

El conjunto de datos al final tendrá m ejemplos (de m posturas) y n características.

Valores para las clases:

- Clase positiva: 1
- Clase negativa: 0

Las descripciones de los conjuntos de datos para cada postura se muestran en la Tabla 10.

Postura	Conjunto de datos final
Postura neutra: De pie con los brazos a los lados	$X \in \mathbb{R}^{1054 \times 42}$ $y \in \mathbb{R}^{1054}$
Postura de movimiento o ejecución: De pie levantando la rodilla izquierda	$X \in \mathbb{R}^{964 \times 42}$ $y \in \mathbb{R}^{964}$
Postura de movimiento o ejecución: De pie levantando la rodilla derecha	$X \in \mathbb{R}^{984 \times 42}$ $y \in \mathbb{R}^{984}$
Postura de movimiento o ejecución: De pie levantando los brazos	$X \in \mathbb{R}^{987 \times 42}$ $y \in \mathbb{R}^{987}$

Tabla 10. Conjuntos de datos para cada postura.

3.2.5. Visualización de los datos

En lo general, se tendrá un desbalance enorme entre las clases, teniendo más ejemplos negativos que positivos, lo cual se debe a que existen muchas posturas aleatorias que se pueden obtener para la clase negativa.

La Tabla 11 muestra visualmente el desbalance de clases que se tiene para cada postura.


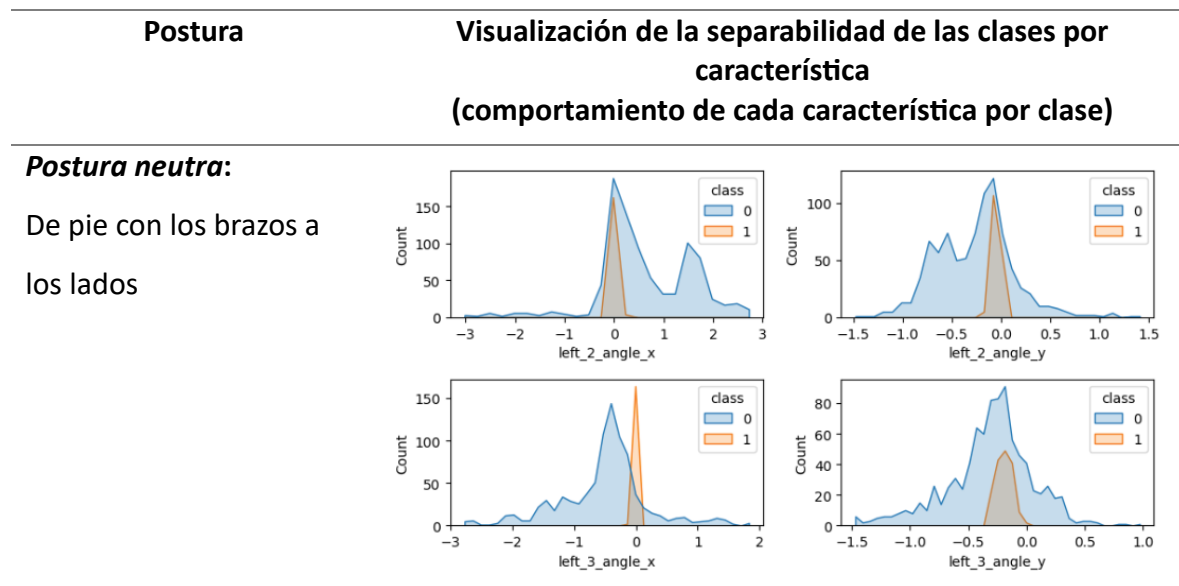


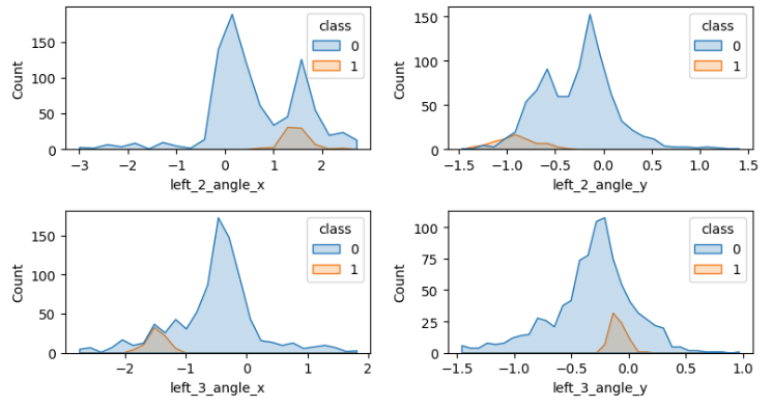
Tabla 11. Desbalance de clases para el problema de clasificación.

Una de las cosas que se suele hacer en un problema de clasificación cuando se tiene el conjunto de datos es visualizar la separabilidad de las clases por característica, así como se muestra en la Tabla 12 (solo para algunas características).

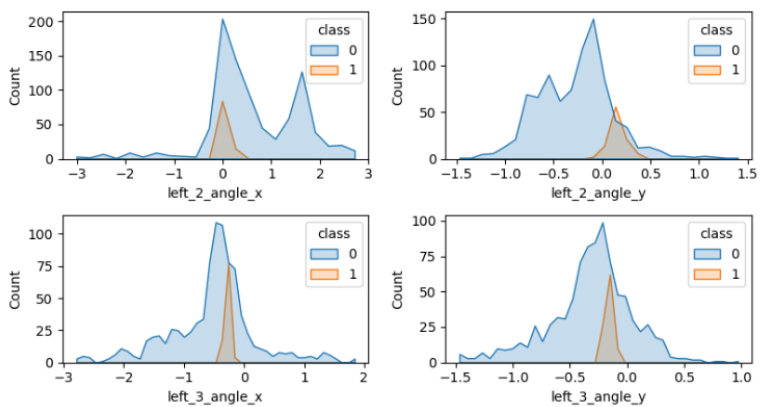


Postura de movimiento o***ejecución:***

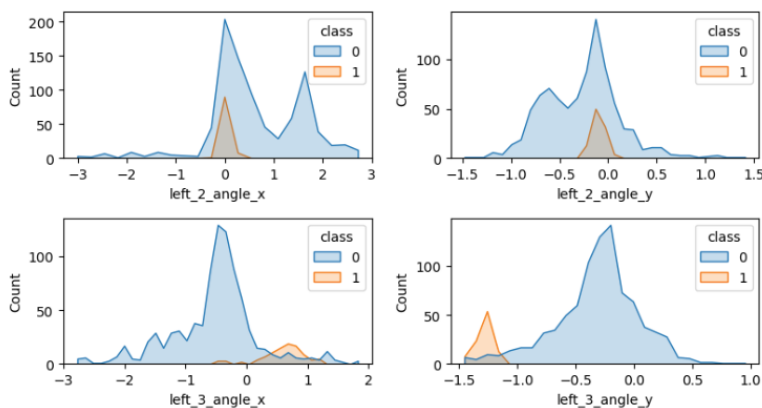
De pie levantando la
rodilla izquierda

***Postura de movimiento o******ejecución:***

De pie levantando la
rodilla derecha

***Postura de movimiento o******ejecución:***

De pie levantando los
brazos



Es de esperarse que para una cierta postura los valores para una cierta característica de la clase positiva tiendan a estar concentrados en un pequeño rango de valores (ya que en una postura fija no hay movimiento). En cambio, para la clase negativa (que son posturas aleatorias), los valores que puede tomar una característica en concreto son muy variados.

NOTA: En el mejor de los casos, las clases tendrían que tender a separarse.

Tabla 12. Separabilidad de las clases por característica.

3.2.6. División del conjunto de datos (entrenamiento y prueba)

Para la división del conjunto de datos se utiliza la estrategia “Stratify” para que la proporción de clases sea la misma tanto en el conjunto de entrenamiento como en el conjunto de prueba.

Se optó por la estrategia 80 y 20 para la separación del conjunto de entrenamiento y prueba, respectivamente.

Conjuntos de datos obtenidos:

- Conjunto de entrenamiento (80% de los datos totales)
- Conjunto de prueba (20% de los datos totales)

Las descripciones de los conjuntos de datos obtenidos se muestran en la Tabla 13.

Postura	Conjunto de entrenamiento	Conjunto de prueba
<i>Postura neutra:</i> De pie con los brazos a los lados	$X_{\text{train}} \in \mathbb{R}^{843 \times 42}$ $y_{\text{train}} \in \mathbb{R}^{843}$ Porcentaje de la clase positiva: 15 % (aprox)	$X_{\text{test}} \in \mathbb{R}^{211 \times 42}$ $y_{\text{test}} \in \mathbb{R}^{211}$ Porcentaje de la clase positiva: 15 % (aprox)
<i>Postura de movimiento o ejecución:</i> De pie levantando la rodilla izquierda	$X_{\text{train}} \in \mathbb{R}^{771 \times 42}$ $y_{\text{train}} \in \mathbb{R}^{771}$ Porcentaje de la clase positiva: 8 % (aprox)	$X_{\text{test}} \in \mathbb{R}^{193 \times 42}$ $y_{\text{test}} \in \mathbb{R}^{193}$ Porcentaje de la clase positiva: 8 % (aprox)
<i>Postura de movimiento o ejecución:</i> De pie levantando la rodilla derecha	$X_{\text{train}} \in \mathbb{R}^{787 \times 42}$ $y_{\text{train}} \in \mathbb{R}^{787}$ Porcentaje de la clase positiva: 10 % (aprox)	$X_{\text{test}} \in \mathbb{R}^{197 \times 42}$ $y_{\text{test}} \in \mathbb{R}^{197}$ Porcentaje de la clase positiva: 10 % (aprox)
<i>Postura de movimiento o ejecución:</i> De pie levantando los brazos	$X_{\text{train}} \in \mathbb{R}^{789 \times 42}$ $y_{\text{train}} \in \mathbb{R}^{789}$ Porcentaje de la clase positiva: 10 % (aprox)	$X_{\text{test}} \in \mathbb{R}^{198 \times 42}$ $y_{\text{test}} \in \mathbb{R}^{198}$ Porcentaje de la clase positiva: 10 % (aprox)

Tabla 13. Conjuntos de datos para entrenamiento y prueba.

3.2.7. Selección de los mejores hiperparametros para el modelo de clasificación

Para la tarea de clasificación se utilizarán las redes neuronales profundas, esto debido a que pueden aprender límites de decisión complejos, lo cual es lo que se busca.

Para tratar el desbalance de clases, se ha decidido ponderar las clases de la siguiente manera:

Ponderación clase negativa:

$$1$$

Ponderación clase positiva:

$$\frac{n_-}{n_+}$$

Donde:

- n_- : Numero de datos negativos utilizados en el entrenamiento
- n_+ : Numero de datos positivos utilizados en el entrenamiento

Con respecto a las arquitecturas de la red, las que se propusieron se muestran en la Tabla 14.

Arquitectura 1								
Capa 0 (capa de entrada)	Capa 1		Capa 2		Capa 3		Capa 4 (capa de salida)	
X	Neuronas	F.A.	Neuronas	F.A.	Neuronas	F.A.	Neuronas	F.A.
	5	Sigmoide	5	Sigmoide	5	Sigmoide	2	Softmax
Arquitectura 2								
Capa 0 (capa de entrada)	Capa 1		Capa 2		Capa 3 (capa de salida)			
X	Neuronas	F.A.	Neuronas	F.A.	Neuronas	F.A.	Neuronas	F.A.
	30	Sigmoide	20	Sigmoide	2			Softmax

F.A.: Función de activación

El resultado de la capa de salida va hacia la función de perdida, la cual cuantifica el error entre lo predicho por el modelo y lo real.

Tabla 14. Arquitecturas de red propuestas.

La estrategia que se utilizó para la selección de la mejor arquitectura de red neuronal y de los mejores hiperparámetros es la de “StratifiedKFold”. El número de folds utilizados fue de 5, y el número de épocas fue de 100. Además, se definió una tolerancia de 1e-6 (0.000001)

para que el entrenamiento se interrumpa cuando la función de pérdida no haya tenido un cambio entre épocas mayor a la tolerancia.

El entrenamiento de las redes neuronales se llevó a cabo en una librería de machine learning que se creó con el propósito de utilizarla en todo momento durante el desarrollo del proyecto.

El flujo de entrenamiento se muestra en la Figura 5.

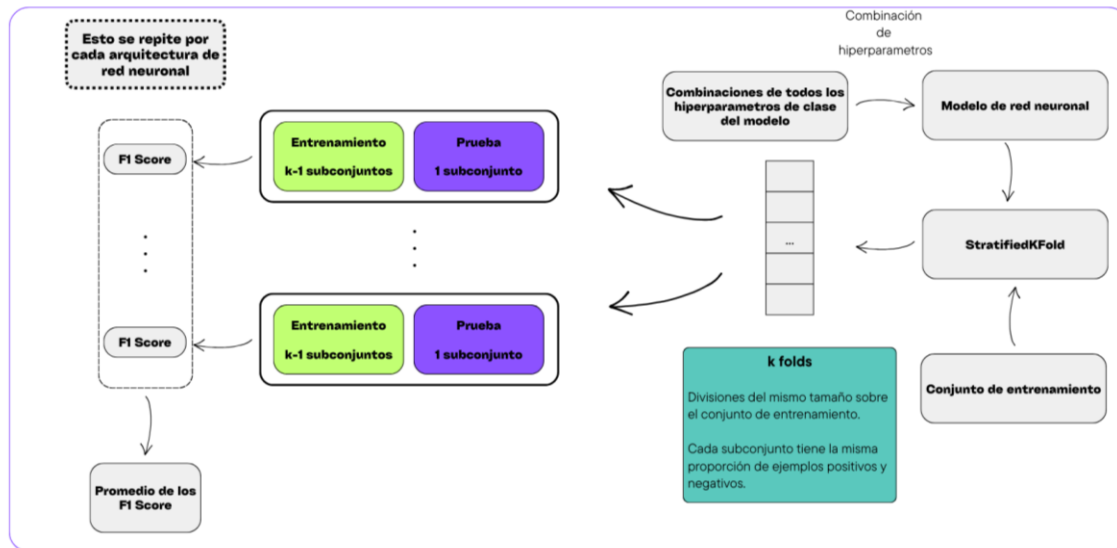


Figura 5. Flujo de entrenamiento para la selección del mejor modelo.

Selección de la mejor arquitectura de red neuronal y de los mejores hiperparámetros:

- Para cada arquitectura, se elige la mejor combinación de hiperparámetros
 - Combinación 1: F1 Score promedio asociado
 - ...
 - Combinación p: F1 Score promedio asociado

Se elige la combinación de hiperparámetros con el F1 Score promedio más alto.

- La mejor arquitectura es aquella con el F1 Score promedio más alto

Para la creación de todas las combinaciones posibles de hiperparámetros se define un diccionario. Para más información consultar el anexo 1.

A partir del diccionario anterior se obtienen combinaciones de hiperparametros que son utilizados por el modelo durante el entrenamiento. Al final se tienen los resultados para cada combinación de hiperparametros.

4. Resultados

En este capítulo se describirán los resultados obtenidos, tanto en regresión como en clasificación. Se mostrarán los resultados obtenidos en la búsqueda del mejor modelo y las métricas utilizadas.

4.1. Clasificación

Se ha optado por entrenar modelos con diferentes combinaciones de hiperparametros para seleccionar aquel modelo con los mejores resultados, ya que para cada problema existe la mejor combinación de hiperparametros, la cual solo es posible determinar comparando los desempeños de los diferentes modelos entrenados.

4.1.1. F1 Score de cada combinación de hiperparametros

Los resultados obtenidos de la métrica “F1 Score” para cada arquitectura y para cada combinación de hiperparametros se muestran en la Tabla 15.

La información de la arquitectura se puede consultar en la Tabla 14, y la información de cada combinación de hiperparametros se puede consultar en el anexo 1.

Postura		
<i>Postura neutra:</i>	Arquitectura	Métrica 'F1 Score' promedio
De pie con los brazos a los lados	1	■ Combinacion 1: 0.9868933766165906
		■ Combinacion 2: 0.9649418424674934
		■ Combinacion 3: 0.989188422085282
		■ Combinacion 4: 0.980564696238415
		■ Combinacion 5: 0.9911741528762805
		■ Combinacion 6: 0.9195740482228457
	2	■ Combinacion 1: 0.9912439990208579
		■ Combinacion 2: 0.9868959754665539
		■ Combinacion 3: 0.9934155377294992
		■ Combinacion 4: 0.9911753883862096
		■ Combinacion 5: 0.9934155377294992
		■ Combinacion 6: 0.9934155377294992

Mejor arquitectura: 2		
Mejor combinación de hiperparámetros: 3		
Postura de	Arquitectura	Métrica 'F1 Score' promedio
movimiento o		
ejecución:		
De pie levantando		
la rodilla izquierda		
	1	■ Combinacion 1: 0.963183958316425
		■ Combinacion 2: 0.8312989620131876
		■ Combinacion 3: 0.9753626850858991
		■ Combinacion 4: 0.801343989655242
		■ Combinacion 5: 0.9700878241345112
		■ Combinacion 6: 0.5175870477058216
	2	■ Combinacion 1: 0.9875414118553731
		■ Combinacion 2: 0.9831880549649139
		■ Combinacion 3: 0.9875414118553731
		■ Combinacion 4: 0.9872362256249183
		■ Combinacion 5: 0.9875414118553731
		■ Combinacion 6: 0.9915895825153775
Mejor arquitectura: 2		
Mejor combinación de hiperparámetros: 6		
Postura de	Arquitectura	Métrica 'F1 Score' promedio
movimiento o		
ejecución:		
De pie levantando		
la rodilla derecha		
	1	■ Combinacion 1: 0.9930407801418439
		■ Combinacion 2: 0.9060011491672476
		■ Combinacion 3: 0.9930407801418439
		■ Combinacion 4: 0.9573701093340562
		■ Combinacion 5: 0.9862709453046575
		■ Combinacion 6: 0.9730801829893949
	2	■ Combinacion 1: 1.0
		■ Combinacion 2: 0.9930346617415037
		■ Combinacion 3: 1.0
		■ Combinacion 4: 1.0
		■ Combinacion 5: 0.9930346617415037
		■ Combinacion 6: 0.9896510018207414

Mejor arquitectura: 2		
Mejor combinación de hiperparámetros: 1		
<i>Postura de</i>	Arquitectura	Métrica 'F1 Score' promedio
<i>movimiento o</i> <i>ejecución:</i> De pie levantando los brazos	1	■ Combinacion 1: 0.9966163400792375
		■ Combinacion 2: 0.9932326801584752
		■ Combinacion 3: 0.9966163400792375
		■ Combinacion 4: 0.9966163400792375
		■ Combinacion 5: 0.9932326801584752
		■ Combinacion 6: 0.9930371767371653
	2	■ Combinacion 1: 1.0
		■ Combinacion 2: 1.0
		■ Combinacion 3: 1.0
		■ Combinacion 4: 0.9930371767371653
		■ Combinacion 5: 1.0
		■ Combinacion 6: 0.9966163400792375
Mejor arquitectura: 2		
Mejor combinación de hiperparametros: 1		

Tabla 15. Resultados obtenidos en la búsqueda del mejor modelo de clasificación.

Al final, para cada clasificador de postura:


- El mejor modelo se entrena con todo el conjunto de entrenamiento
- El mejor modelo cuenta con la mejor arquitectura y los mejores hiperparámetros
- Los parámetros de la red neuronal y los mejores hiperparámetros son guardados para su posterior uso

El historial del costo de la función de perdida para cada clasificador de postura (después de entrenarlo con todo el conjunto de entrenamiento) se muestra en la Tabla 16.

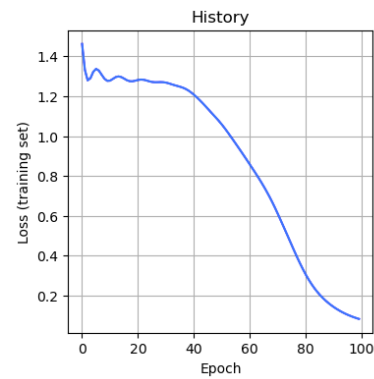
Postura	Costo de la función de perdida en cada época
---------	--

Postura neutra:


De pie con los brazos a los
lados

**Postura de movimiento o****ejecución:**

De pie levantando la rodilla
izquierda

**Postura de movimiento o****ejecución:**

De pie levantando la rodilla
derecha

**Postura de movimiento o****ejecución:**

De pie levantando los brazos


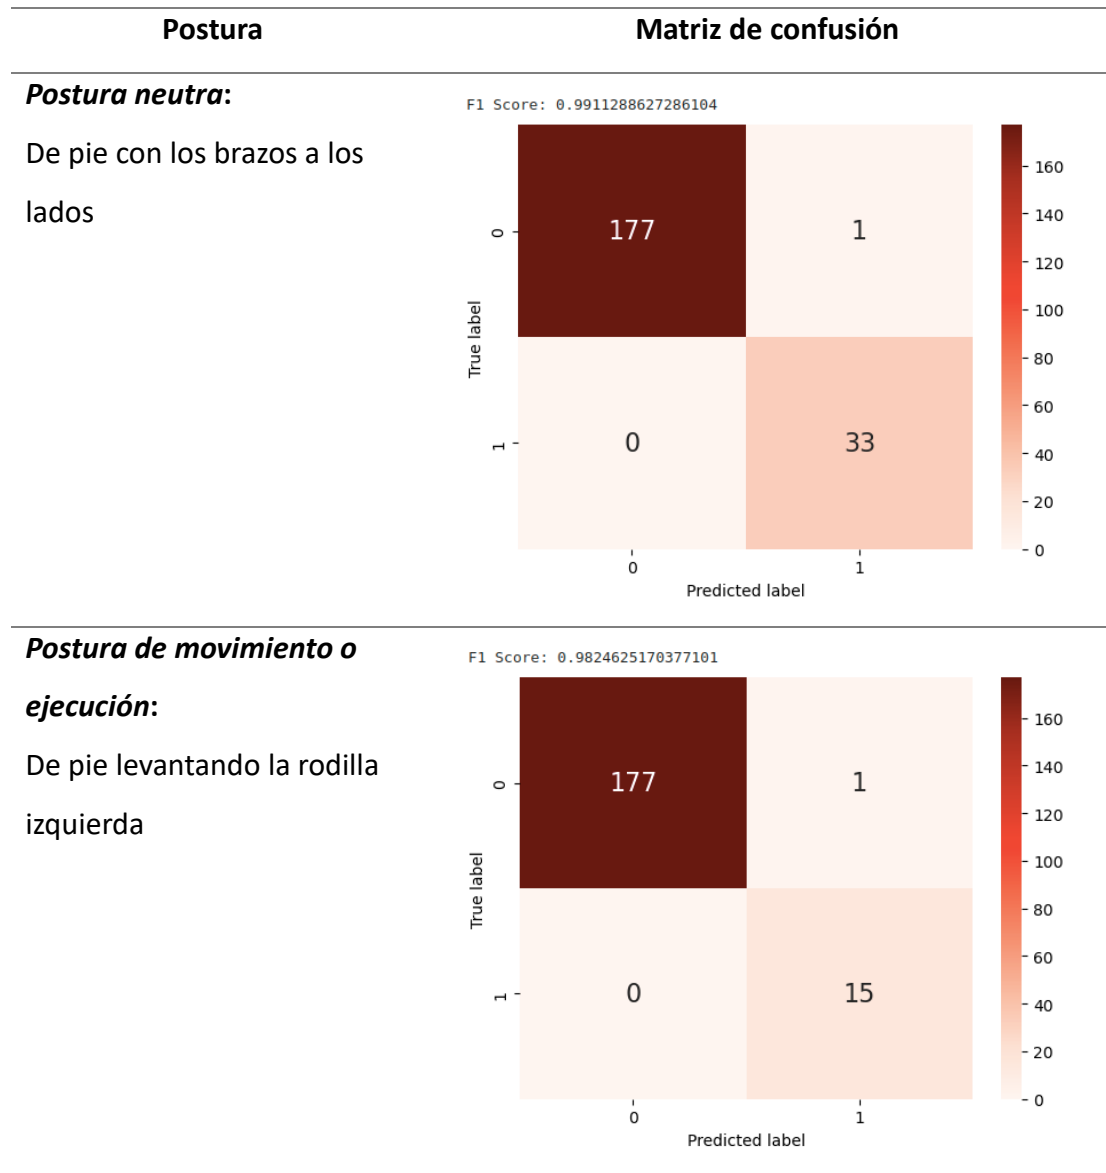


Tabla 16. Historial de perdida durante el entrenamiento.

4.1.2. Resultados en el conjunto de prueba


Para medir el desempeño del modelo se utilizó la métrica “F1 Score”, la cual hace uso de otras métricas resultantes de la matriz de confusión.

Los resultados obtenidos en el conjunto de prueba se muestran en la Tabla 17.



Postura de movimiento o***ejecución:***

De pie levantando la rodilla
derecha

***Postura de movimiento o******ejecución:***

De pie levantando los brazos




Tabla 17. Matrices de confusión para el conjunto de prueba.

Consultar el anexo 2 para más información con respecto a las métricas de evaluación.

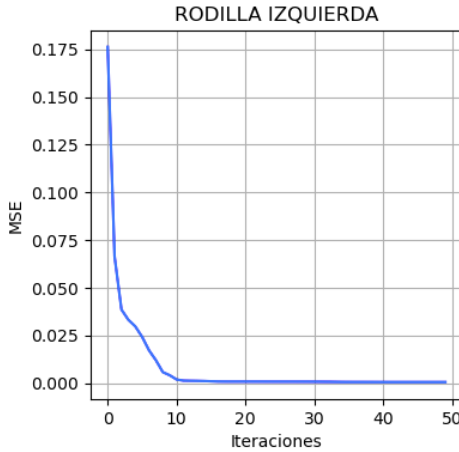
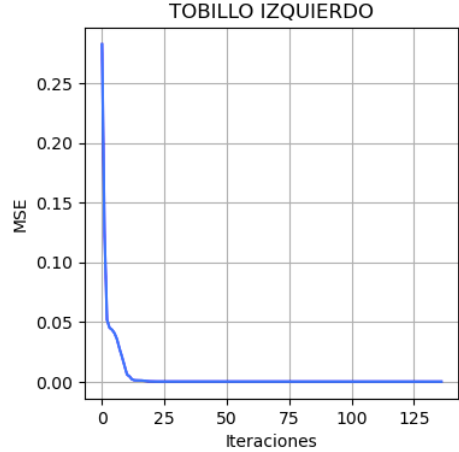
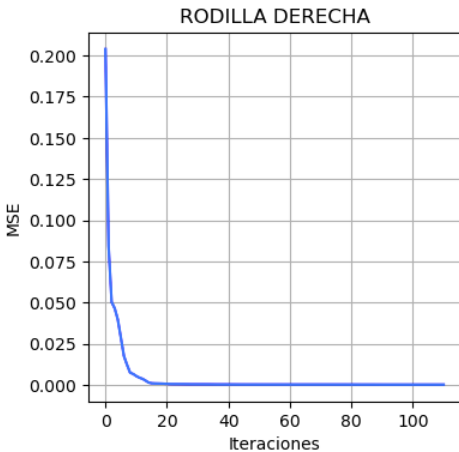
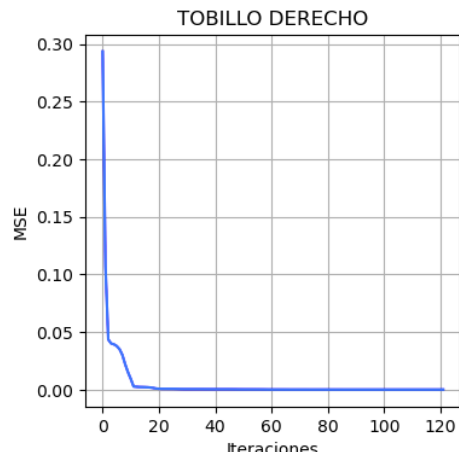
4.2. Regresión

Debido a la gran cantidad de trayectorias que se ajustan (33 trayectorias, una para cada punto 3D), solo se mostraran las trayectorias más relevantes y los resultados obtenidos. Dichas trayectorias se muestran en la Tabla 18.

Para medir el desempeño de las trayectorias ajustadas se utiliza la métrica MSE (error cuadrático medio).

Dado que los puntos están expresados en un sistema de coordenadas global y sus unidades se encuentran en metros, la interpretación que se le pueda dar al resultado de MSE es la

distancia promedio más cercana, en metros cuadrados, que hay entre la trayectoria ajustada y cualquier otro punto de la nube de puntos.

Nombre de la trayectoria	Métrica MSE de la trayectoria ajustada	
	Rodilla izquierda	Tobillo izquierdo
Levantamiento de rodilla izquierda	<p>Historial Costo inicial: 0.1762379952001922 Costo final: 0.000498500008186522</p> 	<p>Historial Costo inicial: 0.28250747269769644 Costo final: 0.00015513986741760106</p> 
Levantamiento de rodilla derecha	Rodilla derecha	Tobillo derecho
	<p>Historial Costo inicial: 0.20383857410792827 Costo final: 0.0003375825521284097</p> 	<p>Historial Costo inicial: 0.29369630311435246 Costo final: 0.00011420249818343843</p> 
	Codo izquierdo	Muñeca izquierda

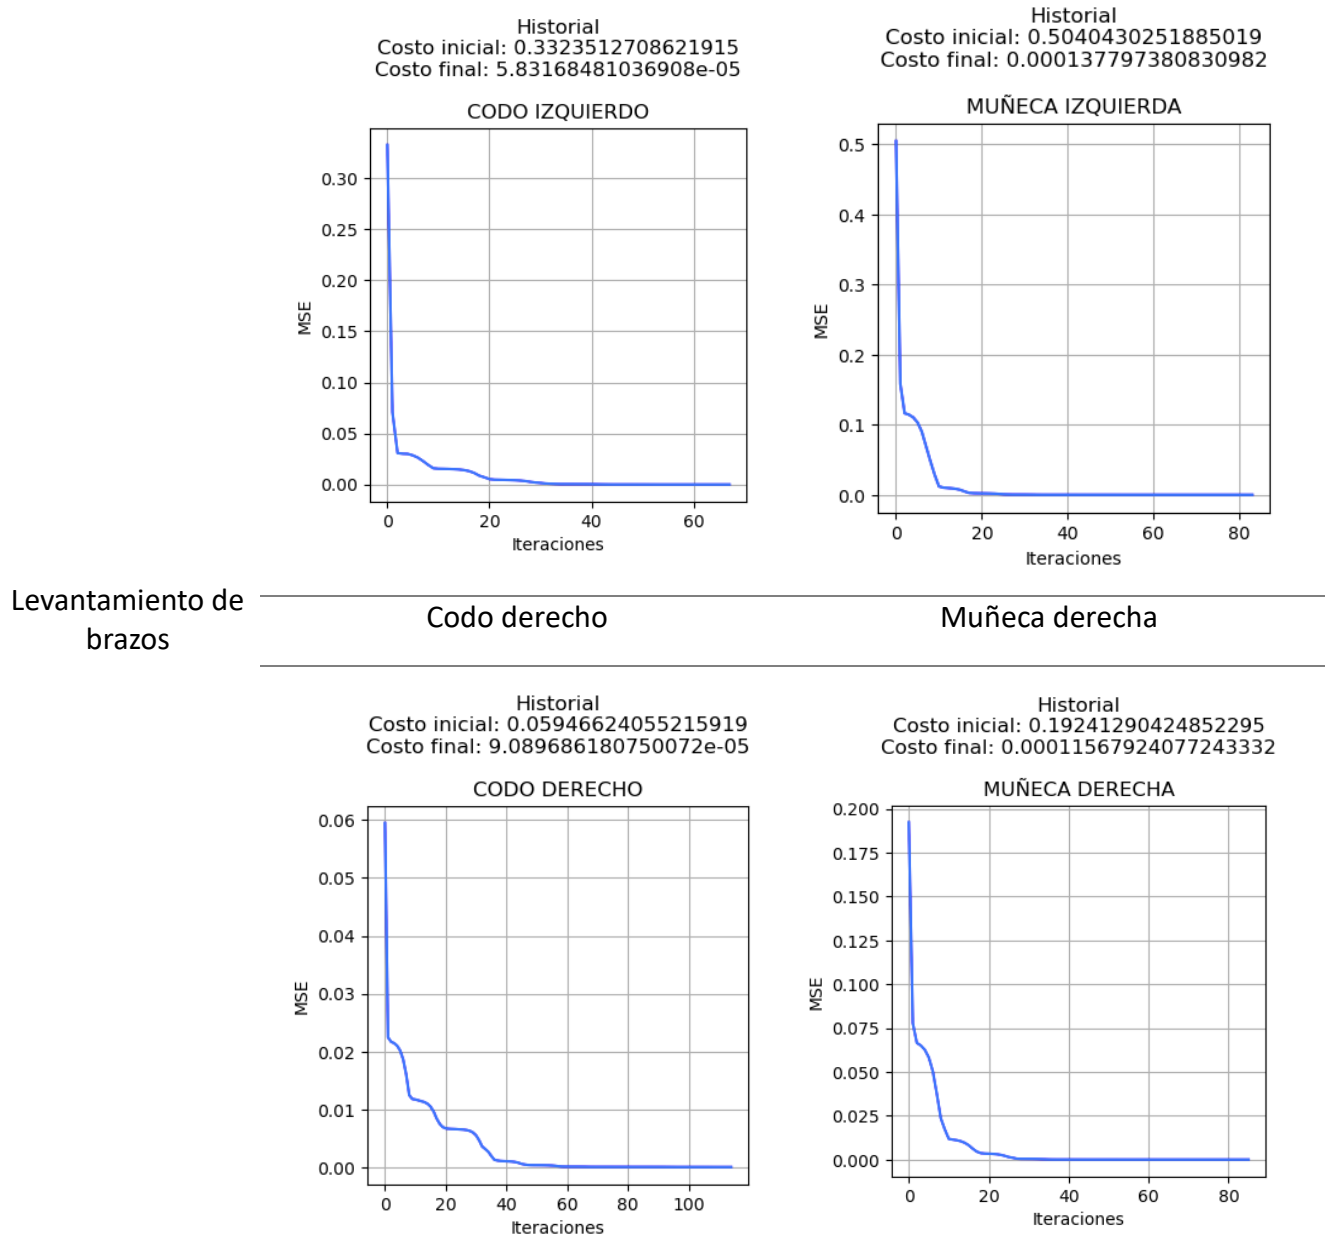


Tabla 18. Historial de perdida para algunas trayectorias.

4.3. Sistema informático

Todos los resultados obtenidos anteriormente se han integrado en un sistema informático para la rehabilitación física mediante rutinas de ejercicio que debe seguir el paciente, cuyas posturas son clasificadas para detectar cuando el paciente ha realizado un ejercicio correctamente. Además, se muestra el movimiento del ejercicio que se le está pidiendo que

realice al paciente (esto por medio de las trayectorias que se ajustaron para poder mostrar una trayectoria más suave del movimiento).

Opciones del menú:

- Calibración de la cámara
- Comprobación de los parámetros de la cámara
- Estimaciones 3D
- Rutina de ejercicio y datos recopilados
- Selección de cámaras para trabajar
- Selección de rutina

Las opciones del menú se muestran en la Figura 6.



Figura 6. Menu del sistema informatico.

El apartado para consultar todos los datos recopilados y para crear rutinas de ejercicios se muestra en la Figura 7.




Figura 7. Visualización de los datos y creación de rutinas en el sistema informático.

El apartado para clasificar las posturas del paciente a lo largo de cada ejercicio de una rutina específica se muestra en la Figura 8.



Figura 8. Clasificación de posturas en el sistema informático.

Enlaces al proyecto:

- Repositorio de github del proyecto:

https://github.com/chuy777777/samsung_final_project.github.io

- Github pages:

https://chuy777777.github.io/samsung_final_project.github.io/

5. Discusión y conclusiones

En este capítulo se discutirán los resultados obtenidos, tanto en regresión como en clasificación. Se discutirán posibles mejoras y el porqué de algunos malos resultados en el ajuste de trayectoria de algunos puntos 3D para el problema de regresión. Además se dará una conclusión general del trabajo realizado.

5.1. Regresión

El ajuste de trayectorias de puntos 3D a lo largo del tiempo dio buenos resultados, tanto la elección de la parametrización de la trayectoria utilizando polinomios de grado 2 para cada componente, como la función de pérdida utilizada (MSE).

Es importante mencionar que los buenos resultados se obtuvieron de aquellos puntos 3D que su nube de puntos describe una trayectoria, ya que los que presentaron malos resultados fueron aquellos puntos 3D que permanecían aproximadamente en el mismo lugar a lo largo del tiempo.

Los resultados podrían mejorarse si solo se toman en cuenta para ajustar una trayectoria aquellos puntos 3D que describen una trayectoria a lo largo del tiempo, y el centroide de aquellos puntos 3D que permanecen en un solo lugar a lo largo del tiempo (ya que su nube de puntos se concentra en una esfera).

5.2. Clasificación

Los resultados obtenidos de la clasificación de las diferentes posturas (postura neutral y postura de movimiento) fue bastante bueno, obteniendo resultados de la métrica F1 Score promedio de 0.98.

Al poner a prueba dichos modelos de clasificación en tiempo real en un sistema informático, se observaron buenas clasificaciones, sin embargo, también hay posturas que son mal clasificadas, lo cual mayormente se debe a que hubo muchas posturas que no se lograron capturar para los datos de la clase negativa, por tanto, existe la posibilidad de que algunas posturas puedan ser clasificadas como positivas cuando realmente no pertenecen a dicha clase.

Planteando soluciones a los problemas que se obtuvieron, capturar más datos de posturas más diversas puede ayudar a tener todavía mejores resultados cuando se prueban los modelos en tiempo real, así también, puede ayudar probar con otros modelos de clasificación que puedan ajustarse y capturar la distribución de la clase positiva (el que un

modelo se ajuste un poco a los datos de la clase positiva no es un problema, al contrario, es deseable para nuestro caso).

Finalmente, a pesar de que los modelos de clasificación (redes neuronales profundas) fueron entrenadas en una librería de machine learning que se creó como parte del proyecto, las predicciones en tiempo real no fueron un problema de rendimiento, ya que solo se realiza el “forward propagation” (construcción del grafo computacional) para obtener las predicciones, no hay cálculo de derivadas en el proceso (ya que no son necesarias, solo en el entrenamiento).

5.3. Conclusión general

Los resultados pueden mejorarse bastante si se mejoran todavía más los procesos de optimización que ocurren en la visión estéreo, tanto la calibración de las cámaras (el problema de optimización que se resuelve, los parámetros de inicialización y el algoritmo de optimización), la corrección de la distorsión de la cámara y el cálculo de puntos 3D a partir de los puntos 2D correspondientes en cada cámara. Esto traería mejores resultados en lo que respecta a la estimación de la pose en 3D.

Dejando de lado la visión estéreo, otras mejoras son el encontrar mejores algoritmos de detección de puntos 2D característicos del cuerpo humano sobre una imagen (que sean mejores a MediaPipe Pose), ya que la estimación de puntos 3D requiere sí o sí que los puntos 2D correspondientes sean precisos.

El uso de sensores, en conjunto con la visión estéreo, podría dar precisión al momento de estimar una pose 3D, ya que se estarían combinando diferentes fuentes de información, lo cual conllevaría a tener mejores resultados al momento de clasificar una postura de una persona.

Finalmente, la implementación de otro modelo de clasificación podría ayudar a tener mejores resultados, tal podría ser el caso de implementar un modelo de hiperesfera que pueda ser moldeable a los datos de la clase positiva, ya que como tal esto agregaría robustez y estaría clasificando como positivo a todos aquellos datos que realmente están dentro de la nube de puntos de la clase positiva.

Referencias

- [1] Muñoz-Cardona, J. E., Henao-Gallo, O. A., & López-Herrera, J. F. (2013). Sistema de Rehabilitación basado en el Uso de Análisis Biomecánico y Videojuegos mediante el Sensor Kinect. *Tecno Lógicas, Edición Especial*, 43-54.
- [2] Uhlrich, S. D., Falisse, A., Kidziński, Ł., Muccini, J., Ko, M., Chaudhari, A. S., Hicks, J. L., & Delp, S. L. (2022). OpenCap: 3D human movement dynamics from smartphone videos. *bioRxiv*. <https://doi.org/10.1101/2022.07.07.499061>
- [3] Keller, A. V., Torres-Espin, A., Peterson, T. A., Booker, J., O'Neill, C., Lotz, J. C., Bailey, J. F., Ferguson, A. R., & Matthew, R. P. (2022). Unsupervised Machine Learning on Motion Capture Data Uncovers Movement Strategies in Low Back Pain. *Frontiers in Bioengineering and Biotechnology*, 10, 868684. <https://doi.org/10.3389/fbioe.2022.868684>
- [4] Phan, T. C., Pranata, A., Farragher, J., Bryant, A., Nguyen, H. T., & Chai, R. (2024). Regression-Based Machine Learning for Predicting Lifting Movement Pattern Change in People with Low Back Pain. *Sensors*, 24(4), 1337. <https://doi.org/10.3390/s24041337>
- [5] Liao, Y., Vakanski, A., & Xian, M. (2020). A Deep Learning Framework for Assessing Physical Rehabilitation Exercises. *IEEE Transactions on Neural Systems and Rehabilitation Engineering*, 28(2), 468–477. <https://doi.org/10.1109/TNSRE.2020.2966249>
- [6] Obukhov, A., Volkov, A., Pchelintsev, A., Nazarova, A., Teselkin, D., Surkova, E., & Fedorchuk, I. (2023). Examination of the Accuracy of Movement Tracking Systems for Monitoring Exercise for Musculoskeletal Rehabilitation. *Sensors*, 23(19), 8058. <https://doi.org/10.3390/s23198058>
- [7] Zago, M., Luzzago, M., Marangoni, T., De Cecco, M., Tarabini, M., & Galli, M. (2020). 3D Tracking of Human Motion Using Visual Skeletonization and Stereoscopic Vision. *Frontiers in Bioengineering and Biotechnology*, 8, 181. <https://doi.org/10.3389/fbioe.2020.00181>

Anexos

1. Combinaciones de hiperparametros

Es posible obtener todas las combinaciones de hiperparametros de un modelo a partir de un diccionario. Su definición se muestra en la Figura 9.

```
class_parameters_dict_list={
  "optimizer": [
    {
      "name": "rmsprop",
      "parameters": {
        "learning_rate": [0.1, 0.01],
        "momentum": [0.5, 0.9],
      }
    },
    {
      "name": "adam",
      "parameters": {
        "learning_rate": [0.1, 0.01],
        "beta_1": [0.9],
        "beta_2": [0.999],
      }
    }
  ],
  "loss_function": [
    {
      "name": "cce",
      "parameters": {
        "weights": [weights]
      }
    }
  ]
}
```

Figura 9. Diccionario de hiperparametros.

A partir del diccionario anterior se obtienen todas las combinaciones de hiperparametros, tal como se muestra en la Tabla 19.

Combinación 1	Combinación 2	Combinación 3
<pre>{ "loss_function":{ "name":"cce", "parameters":{ "weights":{ "0": "1": } } }, "optimizer":{ "name":"rmsprop", "parameters":{ "momentum":0.5, "learning_rate":0.1 } } }</pre>	<pre>{ "loss_function":{ "name":"cce", "parameters":{ "weights":{ "0": "1": } } }, "optimizer":{ "name":"rmsprop", "parameters":{ "momentum":0.5, "learning_rate":0.01 } } }</pre>	<pre>{ "loss_function":{ "name":"cce", "parameters":{ "weights":{ "0": "1": } } }, "optimizer":{ "name":"rmsprop", "parameters":{ "momentum":0.9, "learning_rate":0.1 } } }</pre>
Combinación 4	Combinación 5	Combinación 6



**Pesos asignados a las clases para los diferentes clasificadores de posturas
(de acorde a la estrategia planteada)**

<i>Postura neutra:</i> De pie con los brazos a los lados	<i>Postura de movimiento o ejecución:</i> De pie levantando la rodilla izquierda	<i>Postura de movimiento o ejecución:</i> De pie levantando la rodilla derecha	<i>Postura de movimiento o ejecución:</i> De pie levantando los brazos
Clase positiva: 5.33 Clase negativa: 1.00	Clase positiva: 11.63 Clase negativa: 1.00	Clase positiva: 8.96 Clase negativa: 1.00	Clase positiva: 8.98 Clase negativa: 1.00

Tabla 19. Combinaciones de todos los hiperparametros.

2. Interpretación de las métricas de evaluación para clasificación

La matriz de confusión es ampliamente utilizada para obtener métricas para medir el desempeño de un modelo de clasificación. Las métricas que se pueden obtener se muestran en la Figura 10.

	Predicted Positive	Predicted Negative	
Actual Positive	TP <i>True Positive</i>	FN <i>False Negative</i>	Sensitivity $\frac{TP}{(TP + FN)}$
Actual Negative	FP <i>False Positive</i>	TN <i>True Negative</i>	Specificity $\frac{TN}{(TN + FP)}$
	Precision $\frac{TP}{(TP + FP)}$	Negative Predictive Value $\frac{TN}{(TN + FN)}$	Accuracy $\frac{TP + TN}{(TP + TN + FP + FN)}$

Figura 10. Matriz de confusión.

La Figura 11 muestra la fórmula para la métrica F1 Score, la cual también es muy utilizada debido a su robustez.

$$F1 = \frac{2 \times Precision \times Recall}{Precision + Recall}$$

Figura 11. Métrica F1 Score.

Interpretación de las métricas:

- *Sensitivity (Recall)*

- De todos los ejemplos positivos, ¿qué tanto acertó el modelo?

- *Specificity*

- De todos los ejemplos negativos, ¿qué tanto acertó el modelo?

- *Precision*

- De todas las predicciones positivas, ¿qué tanto acertó el modelo?

- *Accuracy*

- Predicciones correctas / Total

- *F1 Score*

- Es una métrica robusta que toma las métricas 'Precision' y 'Recall'.
- Devuelve cercano a 1 si ambas son también cercanas a 1
- Si una es más grande que la otra, devuelve valores bajos
- Si ambas son bajas, devuelve un valor cercano a 0